# GRUNDLAGEN DES MASCHINELLEN LERNENS

Was wird gemacht? Wie wird es gemacht? Ist das wirklich Lernen?

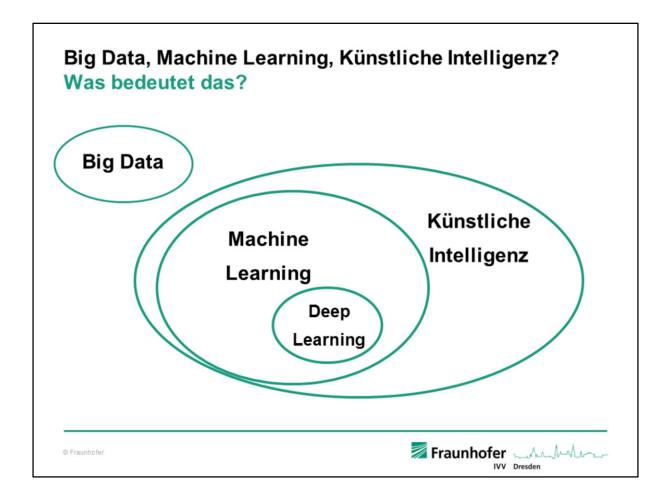


Außenstelle für Verarbeitungsmaschinen und Verpackungstechnik

Dresden, 25. September 2017 Dipl.-Ing. Tilman Klaeger

© Fraunhofer

- Tilman Klaeger
  - Dipl.-Ing. Mechatronik
  - Forschungsgebiet Assistenzsysteme, maschinelles Lernen am Fraunhofer IVV seit Juli 2016



### Big Data:

- Mehr Daten als in den Arbeitsspeicher passen
- Spezielle Methoden erforderlich, z.B. MapReduce
- Beispiel: Google Suchindex => Auf einem Rechner ist diese Datenmenge nicht handhabbar.

## Machine Learning

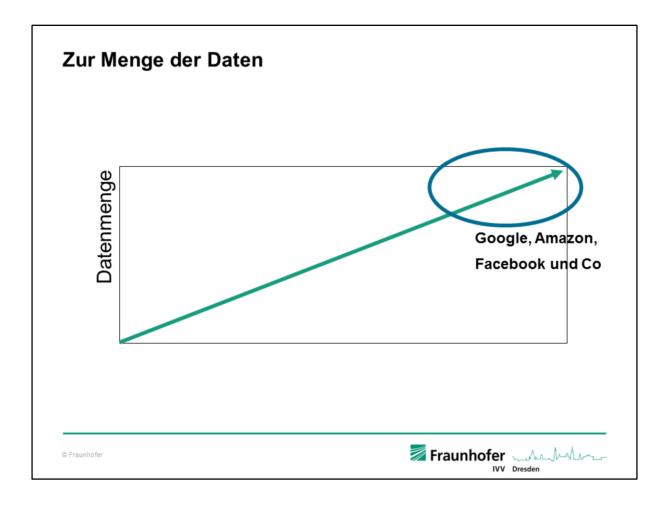
- Automatisches Erkennen von Zusammenhängen in Datensätzen
- Kerntechnologie der künstlichen Intelligenz

# Künstliche Intelligenz

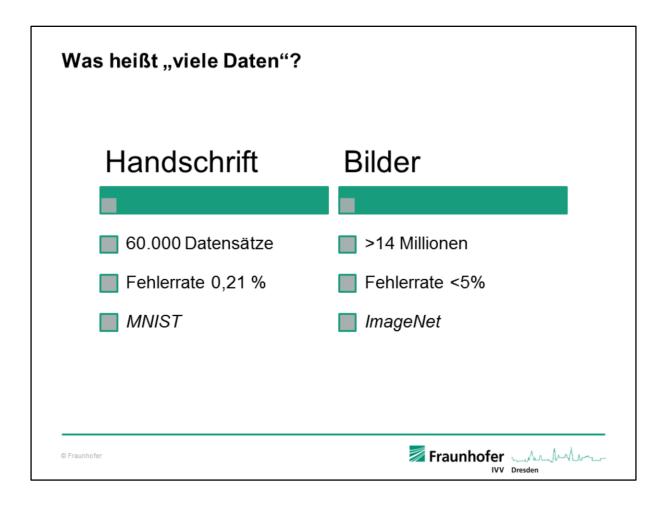
Agiert autonom und verhält sich intelligent [Hecker 17].

# Deep Learning

- Einsatz großer (tiefer) künstlicher Neuronaler Netze
- Vorteil: Kein menschliches Wissen über Prozess im Modell erforderlich



- Aufregende Ergebnisse v.a. aus den USA
  - Datenmenge für Google, Facebook riesig, damit gigantisches Potenzial
  - Alpha GO: Computer gewinnt im Go-Spiel. Datensätze gewonnen indem Computer gegen Computer spielt



### Große Beispieldatensätze im Internet verfügbar

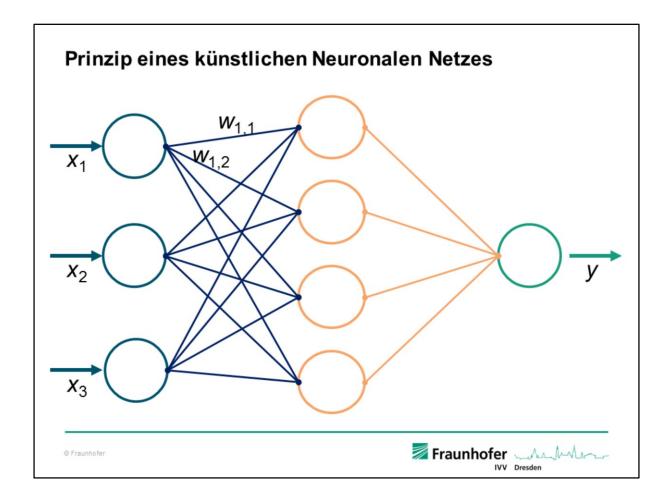
■ regelmäßige Wettbewerbe unter Informatikern

### MNIST

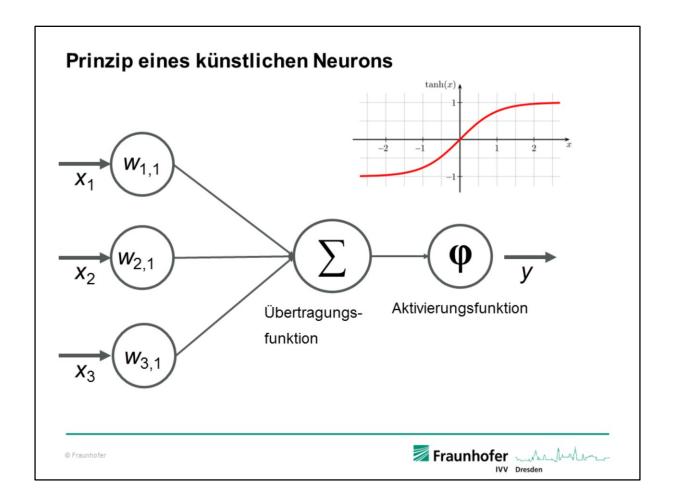
- Kleiner Datensatz für Handschrifterkennung, 60.000 Datensätze
- Fehlerrate bei 0,21% [Vadim 16]

### ImageNet

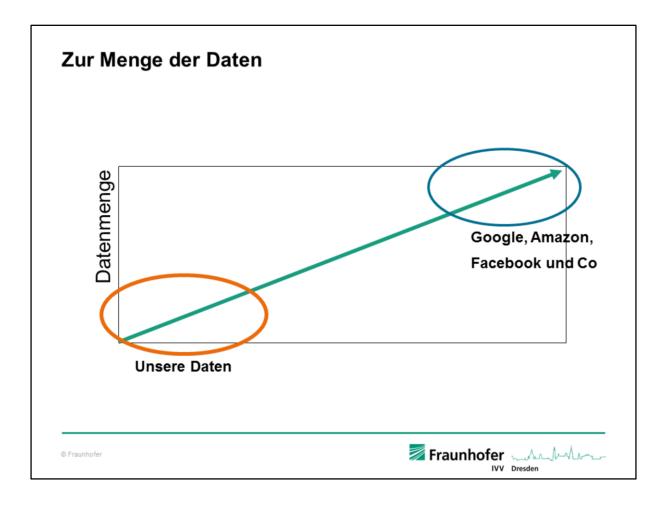
- >14 Millionen manuell zugeordnete Bilder
- Regelmäßige Nutzung für Wettbewerbe zur Bilderkennung
- Ergebnis: Fehlerrate unter 5 % [loffe and Szegedy, 2015], besser als der Mensch



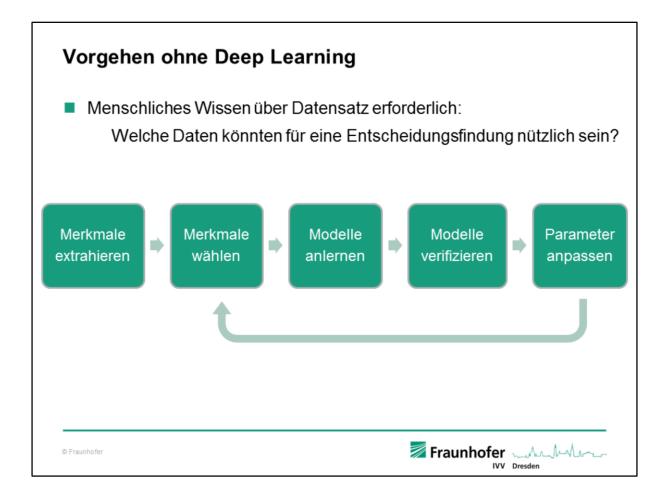
- Feed Forward Netz mit einer versteckten Ebene (Hidden Layer) mit 4 Neuronen
  - Gewichtete Kanten zwischen den Neuronen
  - Jedes Neuron rechnet mit diesen Eingängen einen individuellen Zustand aus und gibt ihn an das nächste Neuron weiter
  - Durch geschickte Algorithmen anpassen der Wichtungen
  - Was im inneren passiert ist schwer zu verstehen, wird häufig als Blackbox betrachtet [Rothe 17].
- Für Deep Learning noch wesentlich größere Netze
  - Aktuell im Trend: Convolutional Netze mit zusätzlicher Verbindung vom Ausgang zum Eingang eines Neurons



- Eingänge eines Neurons werden aufsummiert und in Aktivierungsfunktion geschickt
- Aktivierungsfunktion häufig tanh und andere Funktionen mit einem Ausschlag v.a. im Bereich [-1;1]



- Problem in Forschung: Nur relativ wenig Daten verfügbar
- Analog in vielen Maschinen: Viel Qualitätsprodukt, wenig Störungen => Sehr unausgewogene Datensätze, wenig Daten zum Lernen von Störungen



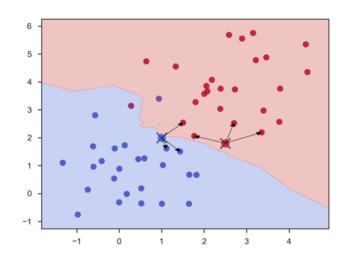
- Am Anfang steht der Mensch, Extraktion der Merkmale aufwendige manuelle Tätigkeit [Domingos 12]
  - Welche Daten sind verfügbar?
  - Was kann ich daraus evtl. ableiten?
  - Welche Daten sind sinnvoll?
- Mit diesen Daten können Modelle angelernt und anschließend verifiziert werden
- Typisch: Iterativer Prozess mit Anpassung der Parameter und häufig auch veränderter Merkmalsauswahl

# Überwachtes Lernen oder unüberwacht? Überwachtes Lernen • Zuordnen von Daten Unüberwachtes Lernen • Aufteilen von Daten Selbstbestärkendes Lernen • Computer lernt sich selber an Fraunhofer NV Dresden

- Überwachtes Lernen
  - Ein Trainingsdatensatz mit bekannten Ergebnisse existiert
- Unüberwachtes Lernen
  - Die Daten werden automatisch in Klassen aufgeteilt.
  - Auch im Bereich Anomalie-Erkennung
  - Überwacht: Bsp Amazon: Wer gerne bestimmte Musik kauft wird auch ein Interesse an schwarzer Kleidung haben. Name der Gruppe egal
- Selbstbestärkendes Lernen
  - Der Computer schafft sich selber Trainingsdaten und lernt an diesen
  - z.B. Alpha Go: Wenn das Spiel gewonnen wurde als positiv klassifizieren

# k Nearest Neighbour

Zugehörigkeit über Distanz von Punkten zu den k nächsten Nachbarn, z.B. nach Euklid  $d = \sqrt{x^2 + y^2}$ 



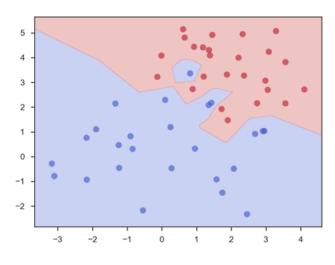
© Fraunhofe



- Zu jedem Punkt werden die *k* (hier *k*=3) nächsten Nachbarn gesucht und damit die Entscheidungsgrenze festgelegt
- Darstellung im Zweidimensionalen Raum gut möglich. Die Mathematik ändert sich in höher-dimensionalen Räumen nicht, nur die Vorstellbarkeit
- Einsatz trotz Einfachheit nach wie vor, häufig mit anderen Distanz-Metriken (Manhattan, Minkowski, Hamming, ...)
  - Auch eigene Distanz-Funktionen denkbar, damit gute Anpassung an eigene Problemstellung möglich



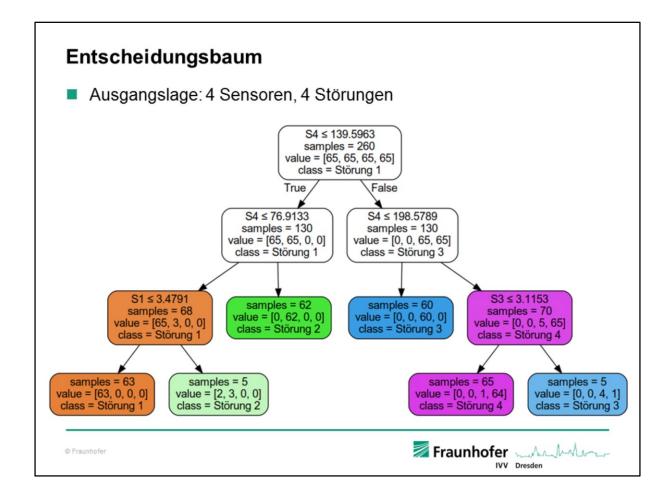
- Der Fehler wird kleiner, aber passt das Modell auch noch für neue Daten?
  - 1 Nachbarn 0 fehlklassifiziert



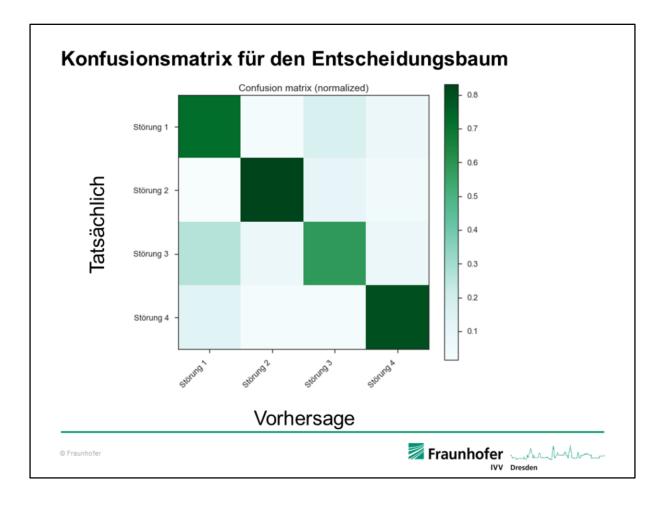
© Fraunhofe



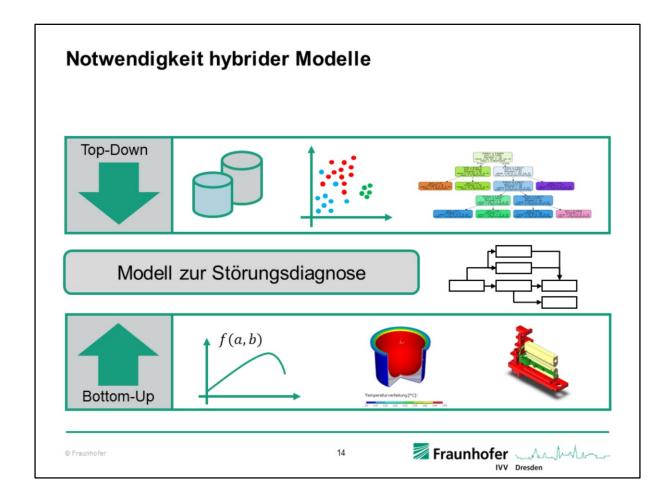
- Durch Anpassen von *k* kann die Generalisierung festgelegt werden.
  - Mehr Nachbarn: Allgemeineres Modell
  - Weniger Nachbarn: Modell lernt immer spezifischer den Datensatz => Überanpassung



- Algorithmus findet Entscheidungskriterien nach überwachtem Lernen
- Wenn Wert Sensor S4 < 76.6 dann Störung 1</p>
- Einsatz eines einzelnen Baums selten, aber viele Modelle nutzen eine Vielzahl kleiner Bäume (Random Forest, Gradient Boosted Decision Trees)
- Visualisierung bei mehr als 2 Dimensionen schwierig
  - Berechnen von Kennwerten wie Genauigkeit: Wieviel Prozent wird mit dem Modell passend zugeordnet. Hier 95%
- Überanpassung: Bei so einem kleinen Baum unwahrscheinlich
- Möglichkeit zur Erweiterung: Viele kleine Bäume ergeben einen Wald, z.B.
   Random Forest [Breiman 2001]



- Auf der linken Achse tatsächlich eingetragene Störung aus dem Datensatz
- Auf der unteren Achse Vorhersage durch das Modell
- Im Idealfall: Nur Diagonale Besetzt
- Eigentlich fast zu gut
  - Nach Prüfung wird festgestellt: S4 zeichnet den Durchmesser der Folienrolle auf.
  - Bei sequentieller Fehlerprovokation ist ein Fehler leicht über die abnehmende Dicke der Folienrolle erkennbar. Aber nur im vorliegenden Fall => Keine Generalisierung mit diesem Modell
  - Wäre bei großen Datenmengen nicht passiert. Hier sind die Daten nicht unabhängig => Scheinkorrelation
- Vorgehen: S4 ignorieren, der sollte auch später nie einen Einfluss haben



- Benötigt wird ein Modell zur Störungsdiagnose
- Die ausschließliche Nutzung stochastischer Modelle (TOP-Down, bspw. mittels maschinellem Lernen) erfordert große Datenmengen → Die notwendige Wiederholung einzelner Störungen muss jedoch möglichst gering sein
- Ziel ist daher die Kombination mit numerischen und empirischen Modellen zum Prozess
  - Dadurch soll eine präzise Modellbildung auch mit wenigen Daten möglich sein
     → das System lernt deutlich schneller

# Ihr Ansprechpartner

### Fraunhofer IVV,

Außenstelle für Verarbeitungsmaschinen und Verpackungstechnik Heidelberger Str. 20, 01189 Dresden

> Tilman Klaeger Tel.: 0351 / 436 14-33 tilman.klaeger@ivv-dresden.fraunhofer.de



© Fraunhofer



# Quellen:

Breiman, L. (2001): Random Forests. Machine Learning. Vol. 45, Nr. 1, S. 5–32.

Domingos, P. (2012): A few useful things to know about machine learning. Communications of the ACM. Vol. 55, Nr. 10, S. 78–87.

Hecker, D. u. a. (2017): Zukunftsmarkt Künstliche Intelligenz – Potenziale und Anwendungen. Fraunhofer-Allianz Big Data. St. Augustin.

loffe, S., Szegedy, C. (2015): Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. Proceedings of the 32nd International Conference on Machine Learning (ICML-15). S. 448–456.

Klaeger, T., Schult, A., Majschak, J.-P. (2017): Lernfähige Bedienerassistenz für Verarbeitungsmaschinen. Industrie 4.0 Management. Vol. 33, S. 25–28.

Rothe, R. (2017): Applying Deep Learning to Real-world Problems, verfügbar unter <a href="http://www.kdnuggets.com/2017/06/applying-deep-learning-real-world-problems.html">http://www.kdnuggets.com/2017/06/applying-deep-learning-real-world-problems.html</a>, abgerufen 24.07.2017.

Vadim, R. (2016): Training Data Expansion and Boosting of Convolutional Neural Networks for Reducing the MNIST Dataset Error Rate. Naukovi Visti NTUU KPI. Nr. 6, S. 29–34.